
Непрерывное время при построении нейроинтерфейса BCI.

Препринт

Соболевский Ф. А.
Кафедра интеллектуальных систем
ФПМИ МФТИ
sobolevskii.fa@phystech.edu

Консультант: Самохина А. М.
Кафедра интеллектуальных систем
ФПМИ МФТИ
alina.samokhina@phystech.edu

Эксперт: д.ф.-м.н. Стрижов В. В.
Вычислительный центр им. А. А. Дородницына
ФИЦ ИУ РАН
strijov@phystech.edu

23 марта 2024 г.

Аннотация

В задачах декодирования сигналов входные данные представляют собой одномерные или многомерные временные ряды. Применение методов, основанных на нейронных обыкновенных дифференциальных уравнениях, позволяет работать с временными рядами как с непрерывными по времени. Подобные методы могут давать заметно более точные по метрикам качества результаты в задачах классификации сигналов, чем методы, работающие с дискретным представлением временных рядов. В данной работе рассматриваются различные методы, основанные на непрерывном представлении временных рядов, в приложении к задаче классификации электроэнцефалограмм (ЭЭГ) и аппроксимации исходного сигнала. Предложенный в работе метод предполагает работу с тензорным представлением сигнала. Основной результат работы – построение модели, работающей с непрерывным по времени тензорным представлением сигнала и анализ эффективности данного метода в сравнении с современными методами обработки сигнала, использующими его дискретное представление.

Ключевые слова: ЭЭГ · непрерывные временные ряды · нейронные ОДУ · тензорное представление сигнала

1 Введение

Данная работа посвящена декодированию сигналов. Примерами актуальных задач декодирования сигналов являются задачи расшифровки сигналов акселерометров, пульсометров, электроэнцефалограмм (ЭЭГ) и электрокортикограмм (ЭКоГ). Многие сигналы, с которыми приходится работать в практических задачах, по природе своей непрерывны по времени, однако распространенный подход к расшифровке сигнала — работа с ним, как с дискретным временным рядом. Основной проблемой при применении такого подхода является нерегулярность данных: данные могут иметь неравные отсчеты по времени или пропуски, что несколько усложняет их обработку.

В ряде недавних работ по обработке временных рядов были предложены новые методы, позволяющие работать с временными рядами как с непрерывными по времени. Таковыми являются, например, методы, основанные на применении нейронных обыкновенных дифференциальных уравнениях (НОДУ) в качестве скрытого слоя рекуррентной нейронной сети (1). В работе (2) был предложен подход, основанный на применении нейронных управляемых дифференциальных уравнений, устраняющий однозначную зависимость решения дифференциального уравнения от начальных данных и корректирующий предсказания нейросети на основе данных, поступающих после исходного предсказания. Другие методы, работающие с непрерывным представлением сигналов, включают в себя нейронные стохастические дифференциальные уравнения (3), алгоритм S4 (4) и другие.

Предполагается, что подходы, работающие с непрерывными по времени данными, устраняют проблемы, связанные с нерегулярностью данных. В некоторых задачах декодирования сигналов методы, основанные на НОДУ, и другие методы, работающие с непрерывным представлением сигнала, показали большую точность, чем методы декодирования дискретных последовательностей (1), (2). В данной работе фокусом являются задачи классификации сигналов головного по признаку наличия в них отклика на некоторый стимул.

В качестве основной задачи декодирования сигнала в данной работе рассматривается классификация ЭЭГ. В последнее время большое количество работ посвящено методам считывания мозговой активности и декодирования информации (5; 6; 7; 8; 9; 10; 11; 12). Основным приложением данных методов являются нейрокомпьютерные интерфейсы (НКИ) — технология, позволяющая человеку взаимодействовать с компьютером с помощью анализа данных о мозговой активности.

Целью данной работы является исследование алгоритмов, основанных на нейронных дифференциальных уравнениях (НДУ), в задаче декодирования ЭЭГ для последующего восстановления непрерывной зависимости движения конечности, и сравнение точности по стандартной метрике MSE с результатами, полученными методами, работающими с дискретным представлением времени. Для этого указанные модели, наряду с современными моделями, работающими с дискретным представлением времени, применяются на выборке P300, содержащей данных ЭЭГ и сведения о наличии импульса P300 в сигнале (13), с целью достижения высокой точности декодирования сигнала и оптимальной сложности модели по количеству параметров.

Применение методов, основанных на НДУ, позволяет работать с ЭЭГ как с непрерывными по времени, что предоставляет возможности дальнейшего исследования непрерывных сигналов, например, в контексте построения фазовых пространств для непрерывного времени и/или пространства. Применимость вышеуказанных методов для решения актуальных задач декодирования сигналов может послужить мотивацией для развития теории моделей машинного обучения, работающих с непрерывными объектными пространствами.

2 Постановка задачи

В задаче классификации сигнала рассматриваются два варианта входных данных: исходные данные, являющиеся регулярными по сетке времени, и изменённые данные, содержащие 80% отсчётов времени, выбранных случайным образом для каждого элемента сигнала.

Для каждой задачи выборка делится на две части: обучающую и валидационную в соотношении 80:20.

2.1 Выборка P300

Регулярные данные. Выборка изначально является регулярной по времени. Пусть, в выборке присутствует M наблюдений. Тогда сигнал и целевая переменная определяются следующим образом:

$$\mathbf{X} = \{\mathbf{X}_i\}_{i=1}^M,$$

$$\mathbf{X}_i = \{\mathbf{x}_t\}_{t \in T}, \mathbf{x}_t \in \mathbb{R}^E, T = \{t_i\}_{i=1}^N, t_i \in \mathbb{R},$$

$$\mathbf{Y} = \{y_i\}_{i=1}^M, y_i \in \{0, 1\},$$

$$\Delta t = t_i - t_{i-1} = \text{const},$$

$E = 8$ — количество электродов,

$N = 40$ — количество наблюдений в одном отрезке ЭЭГ.

Нерегулярные данные. Определение сигнала и целевой переменной для нерегулярных данных совпадает с определением для регулярных, за исключением длины сигнала и шага по времени:

$$\Delta t = t_i - t_{i-1} \neq \text{const}$$

$E = 8$ — количество электродов

$N = 32$ — количество наблюдений в одном отрезке ЭЭГ

Постановка задачи классификации. В парадигме P300 решается задача бинарной классификации отрезков ЭЭГ. Задача — определить наличие в отрезке ЭЭГ потенциала P300.

Для данных, рассмотренных в двух предыдущих разделах, требуется получить целевую функцию:

$$g_\theta : \mathbf{X} \rightarrow \mathbf{Y}.$$

Критерием качества в данной задаче является бинарная кросс-энтропия:

$$L = -\frac{1}{M} \sum_{m=1}^M \left[y_m \log p_m + (1 - y_m) \log(1 - p_m) \right]$$

$p_m = g_\theta(\mathbf{X}_m)$ — вероятность 1 класса для \mathbf{X}_m

Решается оптимизационная задача:

$$\hat{\theta} = \arg \max_{\theta} L(\theta, \mathbf{X}).$$

Внешними критериями качества для задачи классификации являются точность и F1-score.

3 Вычислительный эксперимент

3.1 Постановка эксперимента

Основная цель эксперимента — подобрать оптимальную структуру модели классификации на основе NODE с тензорным представлением сигнала с распространёнными на практике подходами к классификации сигналов.

Постановка эксперимента. Для запуска вычислительного эксперимента использовался набор данных, описанный в следующей секции. Для реализации алгоритмов была использована библиотека PyTorch (14), для автоматизации процесса обучения — Lightning (15).

Набор данных делился на две части: обучающую и валидационную выборки в соотношении 80:20. Для запусков экспериментов на нерегулярных данных производилась модификация исходных данных. Для каждой последовательности случайным образом удалялось 20% точек. Таким образом, шаг по времени между точками становился нерегулярным. Для удобства вычислений длины всех последовательностей сохранялись одинаковыми, что также позволило получить качество классических моделей на нерегулярных данных.

Таким образом, для рассмотренного набора данных было обучено по три модели с использованием Neural ODE. Для набора данных потенциалов P300 также был обучен классификатор на римановской геометрии и свёрточная нейросеть для сравнения качества.

Условия эксперимента. Все модели обучались с помощью библиотеки Lightning. Для обучения моделей использовался алгоритм оптимизации Adam. Оптимизационная задача ставилась относительно критерия перекрёстной энтропии. Параметры оптимизации и количество эпох подбирались экспериментально для каждой из моделей. Для каждой модели в процессе обучения сохранялись три лучших набора параметров, отобранные по F1-score на валидационной выборке. Все запуски обучения производились на CPU.

Список литературы

- [1] Neural Ordinary Differential Equations / Chen Ricky T. Q., Rubanova Yulia, Bettencourt Jesse, and Duvenaud David K // *Advances in Neural Information Processing Systems* / ed. by Bengio S., Wallach H., Larochelle H. et al. — Curran Associates, Inc. — 2018. — Vol. 31. — Access mode: <https://proceedings.neurips.cc/paper/2018/file/69386f6bb1dfed68692a24c8686939b9-Paper.pdf>.
- [2] Neural Controlled Differential Equations for Irregular Time Series / Kidger Patrick, Morrill James, Foster James, and Lyons Terry J. // *NeurIPS*. — 2020. — Access mode: <https://proceedings.neurips.cc/paper/2020/hash/4a5876b450b45371f6cfe5047ac8cd45-Abstract.html>.
- [3] From Noise to Signal: Unveiling Treatment Effects from Digital Health Data through Pharmacology-Informed Neural-SDE. — 2024. — 2403.03274.
- [4] Gu Albert, Goel Karan, Ré Christopher. Efficiently Modeling Long Sequences with Structured State Spaces. — 2022. — 2111.00396.
- [5] Decoding unconstrained arm movements in primates using high-density electrocorticography signals for brain-machine interface use / Hu Kejia, Jamali Mohsen, Moses Ziev B., Ortega Carlos A., Friedman Gabriel N., Xu Wendong, and Williams Ziv M. // *Scientific Reports*. — 2018. — jul. — Vol. 8, no. 1.
- [6] Song Yilin, Wang Yao, Viventi Jonathan. Unsupervised Learning of Spike Patterns for Seizure Detection and Wavefront Estimation of High Resolution Micro Electrocorticographic Data // *IEEE Transactions on NanoBioscience*. — 2017. — sep. — Vol. 16, no. 6. — P. 418–427.
- [7] Loza Carlos A., Principe Jose C. Unsupervised robust detection of behavioral correlates in ECoG // 2017 8th International IEEE/EMBS Conference on Neural Engineering (NER). — IEEE. — 2017. — may.
- [8] Eliseyev Andrey, Aksenova Tetiana. Penalized Multi-Way Partial Least Squares for Smooth Trajectory Decoding from Electrocorticographic (ECoG) Recording // *PLOS ONE*. — 2016. — may. — Vol. 11, no. 5. — P. e0154878.
- [9] Separate spatial and temporal frequency tuning to visual motion in human MT measured with ECoG / Gaglianese Anna, Harvey Ben M., Vansteensel Mariska J., Dumoulin Serge O., Ramsey Nick F., and Petridou Natalia // *Human Brain Mapping*. — 2016. — sep. — Vol. 38, no. 1. — P. 293–307.
- [10] David T Bundy Mrinal Pahwa Nicholas Szrama Eric C Leuthardt. Decoding three-dimensional reaching movements using electrocorticographic signals in humans // *Journal of Neural Engineering*. — 2016. — feb. — Vol. 13, no. 2. — P. 026021.
- [11] Brain-machine interface to control a prosthetic arm with monkey ECoGs during periodic movements / Morishita Soichiro, Sato Keita, Watanabe Hidenori, Nishimura Yukio, Isa Tadashi, Kato Ryu, Nakamura Tatsuhiko, and Yokoi Hiroshi // *Frontiers in Neuroscience*. — 2014. — dec. — Vol. 8.
- [12] Goncharenko V., Grigoryan R., Samokhina A. Raccoons vs Demons: multiclass labeled P300 dataset. — 2020. — 2005.02251.
- [13] Patel Salil H., Azzam Pierre N. Characterization of N200 and P300: Selected Studies of the Event-Related Potential // *Int J Med Sci*. — 2005. — Vol. 2. — P. 147–154. — Access mode: <https://www.medsci.org/v02p0147.htm>.
- [14] PyTorch: An Imperative Style, High-Performance Deep Learning Library / Paszke Adam, Gross Sam, Massa Francisco, Lerer Adam, Bradbury James, Chanan Gregory, Killeen Trevor, Lin Zeming, Gimelshein Natalia, Antiga Luca, Desmaison Alban, Kopf Andreas, Yang Edward, DeVito Zachary, Raison Martin, Tejani Alykhan, Chilamkurthy Sasank, Steiner Benoit, Fang Lu, Bai Junjie, and Chintala Soumith // *Advances in Neural Information Processing Systems 32* / ed. by Wallach H., Larochelle H., Beygelzimer A. et al. — Curran Associates, Inc., 2019. — P. 8024–8035. — Access mode: <http://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf>.
- [15] Falcon WA et al. PyTorch Lightning // *GitHub*. Note: <https://github.com/PyTorchLightning/pytorch-lightning>. — 2019. — Vol. 3.