

---

# Непрерывное время при построении нейроинтерфейса BCI.

---

A Preprint

Соболевский Федор  
Кафедра интеллектуальных систем  
ФПМИ МФТИ  
sobolevskii.fa@phystech.edu

Консультант: Самохина Алина  
Кафедра интеллектуальных систем  
ФПМИ МФТИ  
alina.samokhina@phystech.edu

Эксперт: д.ф.-м.н. Стрижов Вадим  
Вычислительный центр им. А. А. Дородницына  
ФИЦ ИУ РАН  
strijov@phystech.edu

7 марта 2024 г.

## Abstract

В задачах декодирования сигналов входные данные представляют собой одномерные или многомерные временные ряды. Применение методов, основанных на нейронных обыкновенных дифференциальных уравнениях, позволяет работать с временными рядами как с непрерывными по времени. Недавние исследования показывают, что подобные методы могут давать заметно более точные по метрикам качества результаты в задачах классификации сигналов, чем методы, работающие с дискретным представлением временных рядов. В данной работе рассматриваются различные методы, основанные на непрерывном представлении временных рядов, в приложении к задаче классификации электроэнцефалограмм (ЭЭГ) и аппроксимации исходного сигнала. В предложенном подходе к построению модели машинного обучения предполагается работа с функциональным пространством сигнала вместо его дискретного представления и использование пространства параметров аппроксимируемой функции в качестве признакового. Основным результатом работы – построение обратимого потока и подбор оптимальных размерностей на каждом слое нейросети.

Keywords EEG · continuous time series · neural ODE · neural CDE

## 1 Введение

Данная работа посвящена декодированию сигналов — одномерных или многомерных временных рядов. Примерами актуальных задач декодирования сигналов являются задачи расшифровки сигналов акселерометров, пульсометров, электроэнцефалограмм (ЭЭГ) и электрокортикограмм (ЭКГ). Многие сигналы, с которыми приходится работать в практических задачах, по природе своей непрерывны по времени, однако наиболее распространенный подход к расшифровке сигнала — работа с дискретизированной версией сигнала, то есть работа с ним, как с дискретным временным рядом. Основной проблемой при применении такого подхода является нерегулярность данных: данные могут иметь неравные отсчеты по времени или пропуски, что несколько усложняет их обработку.

В ряде недавних работ по обработке временных рядов были предложены новые методы, позволяющие работать с временными рядами как с непрерывными по времени. Таковыми являются, например, методы, основанные на применении нейронных обыкновенных дифференциальных уравнениях (НОДУ) в качестве скрытого слоя рекуррентной нейронной сети. В работе <...> был предложен подход, основанный на применении нейронных управляемых дифференциальных уравнений, позволяющий устранить однозначную зависимость решения дифференциального уравнения от начальных данных, с целью обеспечить возможность корректировки предсказания нейросети на основе данных, поступающих после исходного предсказания. Другие методы, работающие с непрерывным представлением сигналов, включают в себя нейронные стохастические дифференциальные уравнения, алгоритмы S4, S5, D4 и другие.

Подходы, работающие с непрерывными по времени данными, предположительно могут устранить проблемы, связанные с нерегулярностью данных, так как любая нерегулярность может быть устранена интерполяцией. В некоторых задачах декодирования сигналов методы, основанные на НОДУ, и другие методы, работающие с непрерывным представлением сигнала, показали большую точность, чем методы декодирования дискретных последовательностей. В данной работе фокусом являются задачи регрессии — восстановления непрерывной по времени последовательности по непрерывному сигналу.

В качестве основной задачи декодирования сигнала в данной работе рассматривается классификация ЭКоГ. В последнее время большое количество работ посвящено методам считывания мозговой активности и декодирования информации. Основным приложением данных методов являются нейрокомпьютерные интерфейсы (НКИ) — технология, позволяющая человеку взаимодействовать с компьютером с помощью анализа данных о мозговой активности. Подобные интерфейсы могут использоваться как в медицинских целях, так и в рекреационных. Вполне естественно, что для введения устройств, считывающих и расшифровывающих мозговую активность, в эксплуатацию необходимо, во-первых, достичь высокой точности декодирования сигнала, и, во-вторых, достичь оптимальной сложности модели по количеству параметров.

Целью данной работы является исследование алгоритмов, основанных на НОДУ, в задаче декодирования ЭКоГ для последующего восстановления непрерывной зависимости движения конечности, и сравнение точности по стандартной метрике MSE с результатами, полученными методами, работающими с дискретным представлением времени. Для этого указанные модели, наряду с современными моделями, работающими с дискретным представлением времени, применяются на выборке Epidural-ECoG Food-Tracking. Данная выборка содержит данные 8 экспериментов с обезьяной, в которых синхронно считывались сигналы с ЭКоГ и положение 6 точек руки обезьяны.

Применение методов, основанных на НОДУ, позволяет работать с ЭКоГ как с непрерывными по времени, что предоставляет возможности дальнейшего исследования непрерывных сигналов, например, в контексте построения фазовых пространств для непрерывного времени и/или пространства. Применимость вышеуказанных методов для решения актуальных задач декодирования сигналов может послужить мотивацией для развития теории моделей машинного обучения, работающих с непрерывными объектными пространствами.

## 2 Постановка задачи

В данной работе мы имеем дело с сигналами в их непрерывном представлении. Пусть имеется непрерывный процесс (например, активность мозга, движение конечности):

$$V(t), t \in \mathbb{R}$$

Тогда данные выборки, регистрируемый сигнал — реализация процесса  $V(t)$ :

$$\mathbf{X} = \{\mathbf{x}_t\}_{t \in T}, \mathbf{x}_t \in \mathbb{R}^E, T = \{t_i\}_{i=1}^N, t_i \in \mathbb{R}$$

$$\mathbf{x}_{t_i} \approx V(t_i).$$

Для непрерывного и дискретного по времени сигналов решается задачи регрессии. Пусть в выборке присутствует  $M$  наблюдений. Тогда исходный и целевой сигналы определяются следующим образом:

$$\mathbf{X} = \{\mathbf{X}_i\}_{i=1}^M,$$

$$\mathbf{X}_i = \{\mathbf{x}_t\}_{t \in T}, \mathbf{x}_t \in \mathbb{R}^E, T = \{t_i\}_{i=1}^N, t_i \in \mathbb{R}$$

$$\mathbf{Y} = \{\mathbf{Y}_i\}_{i=1}^M,$$

$$\mathbf{Y}_i = \{\mathbf{y}_t\}_{t \in T}, \mathbf{y}_t \in \mathbb{R}^F.$$

Для таких данных постановка задачи регрессии следующая: требуется получить целевую функцию

$$g_\theta : \mathbf{X} \rightarrow \mathbf{Y}.$$

В непрерывном представлении целевой сигнал принимает вид, подобный исходному:

$$U(t), t \in \mathbb{R}, \mathbf{y}_{t_i} \approx U(t_i).$$

Тогда целевая функция есть отображение между двумя пространствами вектор-функций  $\mathbb{V}$  и  $\mathbb{U}$ :

$$g_\theta : \mathbb{V} \rightarrow \mathbb{U}.$$

В обоих случаях критерием качества является отклонение предсказаний модели от известных значений на тестовых данных по стандартной метрике MSE:

$$L = \frac{1}{n} \sum_{i=1}^M ((g_\theta(\mathbf{X}))_{t_i} - \mathbf{y}_{t_i})^2.$$

Решается оптимизационная задача:

$$\hat{\theta} = \arg \min_{\theta} L(\theta, \mathbf{X}).$$

Список литературы